




Situación problema: secuencias de ADN

Análisis y diseño de algoritmos
avanzados

Dra. Valentina Narváez Terán




Tecnológico
de Monterrey


Moléculas del ADN

El ADN está formado por cuatro moléculas, llamadas **bases de nucleótidos**


Adenina (A)




Guanina (G)



Citosina (C)




Timina (T)




Las bases siempre forman los mismos pares:

adenina con timina

citrosina con **guanina**



Moléculas del ADN



Las secuencias de ADN se representan como **largas cadenas** formadas por estas cuatro letras


Dado que las bases siempre se emparejan igual, no es necesario representar todos los pares, basta con una letra por par

De nucleótidos a aminoácidos

Cada grupo de 3 letras forman un “codon”

Puedes imaginarlos como **códigos**, o **instrucciones** que hacen que los ribosomas de las células “impriman” **aminoácidos**

Los aminoácidos se encadenan, formando proteínas



De nucleótidos a aminoácidos

Tabla de aminoácidos
Sirve para traducir cuales tripletas forman cada aminoácido

Amino acid	DNA codons	Amino acid	DNA codons
Ala, A	GCT, GCC, GCA, GCG	Ile, I	ATT, ATC, ATA
Arg, R	CGT, CGC, CGA, CGG; AGA, AGG	Leu, L	CTT, CTC, CTA, CTG; TTA, TTG
Asn, N	AAT, AAC	Lys, K	AAA, AAG
Asp, D	GAT, GAC	Met, M	ATG
Asn or Asp, B	AAT, AAC; GAT, GAC	Phe, F	TTT, TTC
Cys, C	TGT, TGC	Pro, P	CCT, CCC, CCA, CCG
Gln, Q	CAA, CAG	Ser, S	TCT, TCC, TCA, TCG; AGT, AGC
Glu, E	GAA, GAG	Thr, T	ACT, ACC, ACA, ACG
Gln or Glu, Z	CAA, CAG; GAA, GAG	Trp, W	TGG
Gly, G	GGT, GGC, GGA, GGG	Tyr, Y	TAT, TAC
His, H	CAT, CAC	Val, V	GTT, GTC, GTA, GTG
START	ATG	STOP	TAA, TGA, TAG

Nota que varias tripletas pueden resultar en el mismo aminoácido


Por ejemplo, CAT y CAC son Histidina (H)

Amino acid code			
A - Alanine	G - Glycine	M - Methionine	S - Serine
C - Cysteine	H - Histidine	N - Asparagine	T - Threonine
D - Aspartic acid	I - Isoleucine	P - Proline	V - Valine
E - Glutamic acid	K - Lysine	Q - Glutamine	W - Tryptophan
F - Phenylalanine	L - Leucine	R - Arginine	Y - Tyrosine

El código genético de SARS-COV-2

Cada gen induce la creación de varias proteínas

Por ejemplo, el gen *ORF1ab*, abarca la sección resaltada en rojo, y contiene instrucciones para varias proteínas



Situación problema

Un pobre virólogo perdió parte de su investigación. Ayúdale a recuperarla.

- El archivo **SARS-COV-2-MN908947.3.txt** contiene la secuencia genómica de SARS-COV-2, de **Wuhan, 2019**
 - Los siguientes archivos contienen las **secuencias de tres genes**
 - **Gen M:** gen-M.txt
 - **Gen ORF1ab:** gen-ORF1AB.txt
 - **Gen S:** gen-S.txt
 - El archivo **seq-proteins.txt** contiene las secuencias de aminoácidos de las proteínas del virus
 - El archivo **SARS-COV-2-MT106054.1.txt** se obtuvo de muestras de **Texas, en 2020**
1. ¿Cómo **encontrar genes** en la secuencia del virus?
 2. ¿Qué es un palíndromo en el contexto del ADN?
¿Cómo encontrar el palíndromo mas largo en genes?
 3. ¿Cómo encontrar las secciones del virus donde se sintetiza una proteína?
 4. Compara las versiones del genoma del virus de Wuhan, 2019 vs Texas, 2020.
¿Dónde son iguales?
¿Donde que difieren?
¿Las diferencias resultan en aminoácidos diferentes?



Situación problema: entregables

Código Python o C/C++

Las funciones de comparación de strings y búsqueda de palíndromos deben ser programadas por ustedes

NO usar str.find o similares

Reporte:

- Explica el problema, que algoritmos y estructuras de datos usaste. Incluye breves reflexiones individuales al final sobre como fue tu experiencia resolviéndola

¿Cuándo?

11 de octubre (final de semana 3 de periodo 2)

En equipos de 4

Revisa Canvas para saber que debe dar como salidas



Situación problema

El archivo del virus contiene la secuencia del virus, en formato fasta

La primera línea describe a la secuencia

El resto son las letras que representan las bases de nucleótidos: Adenina, Citosina, Guanina, Timina

SARS-COV-2-MN908947.3.txt x

```
1 >MN908947.3 Severe acute respiratory syndrome coronavirus 2 isolate Wuhan-Hu-1, complete genome
2 ATTAAAGGTTTATACCTTCCCAGGTAACAAACCAACCAACTTTCGATCTCTTGTAGATCTGTTCTCTAAA
3 CGAACTTTAAATCTGTGTGGCTGTCACTCGGCTGCATGCTTAGTGCACTCACGCAGTATAATTAATAAC
4 TAATTACTGTCGTTGACAGGACACGAGTAACTCGTCTATCTTCTGCAGGCTGCTTACGGTTTCGTCCGTG
5 TTGCAGCCGATCATCAGCACATCTAGGTTTCGTCCGGGTGTGACCGAAAGGTAAGATGGAGAGCCTTGTC
6 CCTGGTTTCAACGAGAAAACACACGTCCAACCTCAGTTTGCCTGTTTTACAGGTTTCGCGACGTGCTCGTAC
7 GTGGCTTTGGAGACTCCGTGGAGGAGGTCTTATCAGAGGCACGTCAACATCTTAAAGATGGCACTTGTGG
```

Situación problema

Los archivos de cada gen tienen el mismo formato

¿Qué algoritmos puedes utilizar para saber donde ocurre un gen específico en la secuencia del virus?

gen-ORF1AB.txt

```
>MN908947.3:266-21555 Severe acute respiratory syndrome coronavirus 2 isolate  
Wuhan-Hu-1, complete genome  
ATGGAGAGCCTTGTCCTGGTTTCAACGAGAAAACACACGTCCAACCTCAGTTTGCCTGTTTTACAGGTTC  
GCGACGTGCTCGTACGTGGCTTTGGAGACTCCGTGGAGGAGGTCTTATCAGAGGCACGTCAACATCTTAA  
AGATGGCACTTGTGGCTTAGTAGAAGTTGAAAAAGGCGTTTTGCCTCAACTTGAACAGCCCTATGTGTTC  
ATCAAACGTTTCGGATGCTCGAACTGCACCTCATGGTCATGTTATGGTTGAGCTGGTAGCAGAACTCGAAG  
GCATTCAGTACGGTCGTAGTGGTGAGACACTTGGTGTCCTTGTCCTCATGTGGGCGAAATACCAGTGGC  
TTACCGCAAGGTTCTTCTTCGTAAGAACGGTAATAAAGGAGCTGGTGGCCATAGTTACGGCGCCGATCTA  
AAGTCATTTGACTTAGGCGACGAGCTTGGCACTGATCCTTATGAAGATTTTCAAGAAAACCTGGAACACTA  
AACATAGCAGTGGTGTTACCCGTGAACTCATGCGTGAGCTTAACGGAGGGGCATACACTCGCTATGTCGA
```

Situación problema

```
seq-proteins.txt x
>QHD43415_1
MESLVPGFNEKTHVQLSLPVLQVRDVLVRGFGDSVEEVLSEARQHLKDGTGCLVEVEKGVLPQLEQPYVFIKRSDA
VALEGIQYGRSGETLGVLVPHVGEIPVAYRKVLLRKNNGKAGGHSYGADLKSFDLGDELGTDPYEDFQENWNTK
I NGG
>QHD43415_2
AYTRYVDNNFCGPDGYPLECIKDLLARAGKASCTLSEQLDFIDTKRGVYCCREHEHEIAWYTERSEKSYELQTPFE
ECPNFVFPLNSIIKTIQPRVEKKKLDGFMGRIRSVYPVASPNECNQMCLSTLMKCDHCGETSWQTGDFVKATCEFC
CGYLPQNAVVKIYCPACHNSEVGPEHSLAEYHNESGLKTI LRKGGRTIAFGGCVFSYVGCHNKCAWVPRASANIG
GLNDNLLEILQKEKVNINIVGDFKLNEEIAIILASFSAFVETVKGLDYKAFKQIVESC GNFKVTKGKAKKGA
LYAFASEAARVRSIFSRTLTAQNSVRVLQKAAITILDGISQYSLRLIDAMMFTSDLATNNLVVMAYITGGVVQL
YEKLKPVLDWLEEFKEGVEFLRDGWEIVKFISTCACEIVGGQIVTCAKEIKESVQTFKLVNKFALCADSIIIG
FVTHSKGLYRKCVKSREETGLLMPLKAPKEIIFLEGETLPTEVLTEEVVLTGDLQPLEQPTSEAVEAPLVGTPVC
FKYCALAPNMMVTNNTFTLKGG
>QHD43415_3
APTKVTFGDDTVIEVQGYKSVNITFELDERIDKVLNEKCSAYTVELGTEVNEFACVVADAVIKTLQPVSELLTPLG
LFDESGEFKLASHMYCSFYPPDEDEEEEGDCEEEEFEPSTQYEYGTEDDYQGKPLEFGATSAALQPEEEQEEDWLDD
EDNQTTTIQTIVEVQPPQLEMELTPVVQTI EVNSFSGYLKLTDNVYIKNADIVEEAKKVKPTVVVNAANVYLKHGGG
MQVESDDYIATNGPLKVGGS CVLSGHNLA KHCLHVVGPNVNGEDIQLLKSAYENFNQHEVLLAPLLSAGIFGADP
TNVYLAVFDKNLYDKLVSSFLEMKSEKQVEQKIAEIPKEEVKPFITESKPSVEQRKQDDKKIKACVEEVT TTLEET
```

El archivo **seq-proteínas.txt** contiene las cadenas de aminoácidos de las proteínas. Por cada proteína se lista su nombre, seguido de los aminoácidos que la forman

La primera es:

>QHD43415_1
MESLVPGFNEKTHVQLS...

La segunda es:

>>QHD43415_2
AYTRYVDNNFCGPDGYPL...

Y la tercera:

>QHD43415_3
APTKVTFGDDTV...

Situación problema

Amino acid	DNA codons	Amino acid	DNA codons
Ala, A	GCT, GCC, GCA, GCG	Ile, I	ATT, ATC, ATA
Arg, R	CGT, CGC, CGA, CGG; AGA, AGG	Leu, L	CTT, CTC, CTA, CTG; TTA, TTG
Asn, N	AAT, AAC	Lys, K	AAA, AAG
Asp, D	GAT, GAC	Met, M	ATG
Asn or Asp, B	AAT, AAC; GAT, GAC	Phe, F	TTT, TTC
Cys, C	TGT, TGC	Pro, P	CCT, CCC, CCA, CCG
Gln, Q	CAA, CAG	Ser, S	TCT, TCC, TCA, TCG; AGT, AGC
Glu, E	GAA, GAG	Thr, T	ACT, ACC, ACA, ACG
Gln or Glu, Z	CAA, CAG; GAA, GAG	Trp, W	TGG
Gly, G	GGT, GGC, GGA, GGG	Tyr, Y	TAT, TAC
His, H	CAT, CAC	Val, V	GTT, GTC, GTA, GTG
START	ATG	STOP	TAA, TGA, TAG

Para encontrar cual sección del virus produce a una proteína, debes decodificarla

Ejemplo:

La primera proteína es QHD434I5_I, y sus primeros tres aminoácidos son

M E S

M es ATG

E es GAG... y también GAA

S podría ser TCT, TCC, TCA, AGT, o AGC

¿Qué estructura permitiría encontrar rápido los diferentes códigos posibles de un aminoácido?

Amino acid code

A - Alanine	G - Glycine	M - Methionine	S - Serine
C - Cysteine	H - Histidine	N - Asparagine	T - Threonine
D - Aspartic acid	I - Isoleucine	P - Proline	V - Valine
E - Glutamic acid	K - Lysine	Q - Glutamine	W - Tryptophan
F - Phenylalanine	L - Leucine	R - Arginine	Y - Tyrosine

Fuentes y recursos

Secuencias de Sars-Cov-2 y genes (tomados de MN908947.3)

<https://www.ncbi.nlm.nih.gov/nuccore/MN908947.3>
<https://www.ncbi.nlm.nih.gov/nuccore/MT106054.1>

Secuencias de las proteínas (corresponden a MN908947.3)
<https://zhanggroup.org/COVID-19/index.html#download>

Investiga:

¿Cómo se decide a partir de cual posición se comienzan a agrupar tripletas en codones?

Pistas: conceptos de marco de lectura (frame), UTR-5, UTR-3

¿Cómo calcular la subcadena común mas larga de dos cadenas?

¿En que podría ser útil en la situación problema?